CUN · COMPUTACIÓN EN LA NUBE · ACA 1 · PROYECTO 2: EDUCACIÓN

TRAYECTORIA-UCI

Datos y evidencia para la permanencia estudiantil

Recuperación semántica con perfiles descriptivos y fuentes verificables

4.424
registros · 36 variables + Target

7
perfiles estadísticos

3 / 154
documentos / páginas

319
pasajes indexados

01 Problema y objetivo

Los datos de trayectoria y las orientaciones de apoyo suelen consultarse por separado. Su integración exige conservar la procedencia y distinguir los resultados observados de las recomendaciones institucionales.

Objetivo: recuperar pasajes sobre acompañamiento, bienestar y financiación, vinculándolos con perfiles agregados del dataset mediante SQL y búsqueda vectorial.

Estados observados en el dataset



Graduación	Abandono	En curso
49,9 %	**32,1 %**	**17,9 %**

Fuente: Realinho et al. (2021).

02 Corpus y alcance

MEN · 2016 · 55 páginas

Lineamientos de política de bienestar para instituciones de educación superior.

Universidad El Bosque · 2024 · 48 páginas

Política para el éxito estudiantil y lineamientos de acompañamiento.

Universidad Nacional · 2022 · 51 páginas

Guía de acompañamiento para estudiantes y tutores de posgrado, 4.ª edición.

Ámbitos diferenciados: el dataset procede de Portugal; las fuentes colombianas aportan contexto temático. No se vinculan personas ni se infieren efectos causales.

03 Arquitectura

CSV → SQLite: 7 perfiles
PDF → extracción por página física

↓

Párrafos de hasta 280 tokens
Solapamiento: hasta 50; 40 en cortes largos

↓

E5 · 384 dimensiones (Wang et al., 2024)
passage: documentos / query: preguntas

↓

Qdrant · coseno · lotes de 64
Fuente explícita → 20 candidatos

↓

Cross-Encoder (s. f.) → Top-3 + SQL
Validación local; destino: Qdrant Cloud

04 Resultados de recuperación

Método / banco	Hit@3	MRR@3	nDCG@3	p50 (ms)
E5 · desarrollo (12)	**58,3 %**	**0,486**	**0,511**	**24,0**
E5 + Cross-Encoder · desarrollo (12)	**75,0 %**	**0,653**	**0,678**	**1519,1**
E5 + Cross-Encoder · reserva (6)	**83,3 %**	**0,833**	**0,833**	**1482,5**

Pertinencia por fuente, página y pasaje. Igual filtro institucional en ambos métodos; reserva interna de seis preguntas con configuración fija. Tres mediciones por consulta tras calentamiento. Las puntuaciones de reordenamiento y coseno se interpretan por separado.

05 Consultas y acceso

Apoyos ante dificultades económicas (MEN)

Top-1: MEN, p. 28 · coseno 0,8499
Pasaje y perfiles vinculados disponibles en el notebook.

Asignaturas con pérdidas académicas (El Bosque)

Top-1: El Bosque, p. 26 · coseno 0,8676
Pasaje y perfiles vinculados disponibles en el notebook.

CÓDIGO Y FUENTES

VER VIDEO

Referencias

Cross-Encoder. (s. f.). *mmarco-mMiniLMv2-L12-H384-v1* [Ficha de modelo]. Hugging Face. https://huggingface.co/cross-encoder/mmarco-mMiniLMv2-L12-H384-v1

Ministerio de Educación Nacional. (2016). *Lineamientos de política de bienestar para instituciones de educación superior.* https://usbcali.edu.co/wp-content/uploads/2023/10/lineamientos_de_politica_de_bienestar_para_ies.pdf

Realinho, V., Vieira Martins, M., Machado, J., & Baptista, L. (2021). *Predict students' dropout and academic success* [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C5MC89

Universidad El Bosque. (2024). *Política para el éxito estudiantil y lineamientos.* https://www.unbosque.edu.co/sites/default/files/2024-10/PoliticadeExitoEstudiantil.pdf

Universidad Nacional de Colombia. (2022). *Guía de acompañamiento para estudiantes y tutores de Posgrado de la Universidad Nacional de Colombia* (4.ª ed.). https://posgrados.unal.edu.co/wp-content/uploads/2024/01/GuiaAcompanamientoEstudiantesTutores_Agosto2022.pdf

Wang, L., Yang, N., Huang, X., Yang, L., Majumder, R., & Wei, F. (2024). *Multilingual E5 text embeddings: A technical report.* arXiv. https://doi.org/10.48550/arXiv.2402.05672